

Graph Triage

Triagem médica automática por classificação textual baseada em grafos

Sem bibliotecas de ML · Implementado do zero

Grafo tripartite

Label Propagation

Índice invertido

IDF

Stemming PT-BR



Como encaminhar uma queixa para a especialidade certa?

"dor no peito e falta de ar, com leve dor lombar ao carregar peso"

CONTEXTO REAL

Em prontos-socorros e telemedicina, o paciente descreve em linguagem natural — informal, ambígua, com sinônimos e sobreposição de sintomas entre especialidades.

NOSSA ABORDAGEM

Modelar as relações entre textos, palavras e categorias como um grafo. A classificação emerge da topologia — sem treinar nenhum modelo estatístico.

500 queixas · 5 especialidades

500

queixas no corpus

400

rotuladas para treino

100

ambíguas para classificar

5

especialidades-alvo

Cardiologia

Neurologia

Ortopedia

Dermatologia

Gastroenterologia

As queixas ambíguas misturam termos de 2–3 categorias intencionalmente — o teste real da capacidade do grafo de resolver ambiguidade pela força dos vizinhos.

Pipeline do zero

01 Pré-processamento

Tokenização · stopwords PT-BR · stemming Snowball — 'dores/dor/doendo' viram o mesmo radical

02 Índice invertido

Hash aninhada: termo $\rightarrow$ {doc: freq}. Consulta em $O(1)$. Centraliza o cálculo de IDF.

03 Construção do grafo tripartite

Vértices: documento, termo, categoria. Arestas ponderadas por frequência $\times$ IDF.

04 Label Propagation

Média ponderada iterativa pelos vizinhos. Converge em ~ 46 iterações. $O(\text{iter} \times \text{arestas})$.

05 Avaliação + visualização

Holdout 20% · acurácia · matriz de confusão · gráficos de convergência

Grafo tripartite não-direcionado



DOCUMENTOS

500

queixas médicas
sem arestas diretas entre si



TERMOS

443

radicais únicos
ponte entre docs e categorias



CATEGORIAS

5

especialidades
vértices âncora com scores fixos

Doc ↔ Termo · 2.232 arestas · peso = freq

Termo ↔ Cat · 586 arestas · peso = co-oc × IDF

Doc ↔ Cat · 320 arestas · peso = 1.0 (fixo, âncora rotulada)

Representação: lista de adjacência via dicionários — $O(V+E)$ de memória vs $O(V^2)$ de uma matriz. Escolha justificada pela esparsidade do grafo.

Label Propagation

ETAPA 01

Inicialização

Categorias e docs rotulados recebem score 1.0 e ficam fixos. Demais vértices começam em zero.

ETAPA 02

Propagação iterativa

Cada vértice não-fixo recebe a média ponderada dos scores dos seus vizinhos. Repete até convergir.

ETAPA 03

Predição

A categoria de maior score final é o resultado. O valor do score é a confiança da classificação.

$$\text{score}(v, c) = \sum \text{peso}(v, u) \cdot \text{score}(u, c) / \sum \text{peso}(v, u)$$

Converge em ~46 iterações · $\epsilon = 1 \times 10^{-4}$ · complexidade $O(\text{iter} \times |\text{arestas}|)$

Acurácia em dois cenários

HOLDOUT (20% ROTULADAS)

86,2%

vs. 20% de acerto ao acaso com 5 classes

QUEIXAS AMBÍGUAS U*

87,0%

gabarito oculto, nunca visto no treino

Ortopedia



100%

Neurologia



~90%

Dermatologia



~85%

Cardiologia



81,2%

O que o projeto demonstra

Topologia como classificador

A decisão emerge da estrutura do grafo, não de um modelo treinado. Nenhuma biblioteca de ML.

Índice invertido como fundação

Reduz a montagem do grafo de $O(D \times T \times D)$ para $O(\text{arestas})$. A estrutura de dados importa.

IDF resolve ambiguidade

"dor" aparece em 3 especialidades. Sem IDF, o modelo enviesa. Com IDF, termos discriminativos dominam.

Erros são interpretáveis

Neurologia ↔ Cardiologia: tontura e suor nas duas. As falhas refletem sobreposição clínica real.

87% de acurácia em triagem de texto livre em português informal — implementando grafo e propagação do zero. A estrutura de dados resolveu o problema de PLN.